

Mini-Projet 3 : Méthode d'Uzawa pour un SVM linéaire appliqué au WAAM

Binôme : EL HICHO Ahmed & EL FILALI Yassine

Encadrant : Prof. ZOUHRI Wahb

École : Arts et Métiers Campus de Rabat



Contexte et problématique

Le procédé *Wire Arc Additive Manufacturing* (WAAM) permet de fabriquer des pièces métalliques en déposant du métal sous forme de fil fondu. Deux paramètres de réglage importants sont la vitesse de dépôt V_d (en cm/min) et la vitesse d'alimentation du fil V_{fil} (en m/min). Un mauvais réglage de ces vitesses entraîne des défauts (porosité, manque de fusion, etc.) et une non-conformité de la pièce. On dispose d'un ensemble d'essais répertoriant la conformité (étiquetée +1 pour conforme et -1 pour non conforme) en fonction de V_d et V_{fil} . L'objectif est de construire un modèle prédictif linéaire qui sépare au mieux les données et de l'implémenter avec l'algorithme d'Uzawa.

1 Formulation du problème SVM

Pour une base d'apprentissage $(x_i, y_i)_{i=1}^n$ avec $x_i \in \mathbb{R}^d$ et $y_i \in \{-1, +1\}$, un *support vector machine* linéaire cherche un hyperplan de décision $f(x) = w^T x + b$ tel que

$$y_i(w^T x_i + b) \geq 1 \quad \text{pour tous } i = 1, \dots, n. \quad (1)$$

Lorsque l'ensemble est séparé linéairement, le problème primal consiste à minimiser la norme du vecteur de poids :

$$\min_{w, b} \frac{1}{2} \|w\|^2 \quad \text{sous les contraintes} \quad y_i(w^T x_i + b) \geq 1. \quad (2)$$

1.1 Lagrangien et dérivées

On introduit des multiplicateurs de Lagrange $\lambda_i \geq 0$ et on définit le Lagrangien

$$\mathcal{L}(w, b, \lambda) = \frac{1}{2} \|w\|^2 + \sum_{i=1}^n \lambda_i (1 - y_i(w^T x_i + b)). \quad (3)$$

Pour résoudre le problème de manière incrémentale, l'algorithme d'Uzawa alterne une minimisation de $\mathcal{L}$ par rapport aux variables primales (w, b) et une maximisation par rapport aux multiplicateurs λ . Les gradients utiles sont :

$$\nabla_w \mathcal{L}(w, b, \lambda) = w - \sum_{i=1}^n \lambda_i y_i x_i, \quad (4)$$

$$\frac{\partial \mathcal{L}}{\partial b}(w, b, \lambda) = - \sum_{i=1}^n \lambda_i y_i, \quad (5)$$

$$\frac{\partial \mathcal{L}}{\partial \lambda_i}(w, b, \lambda) = 1 - y_i(w^T x_i + b). \quad (6)$$

Le terme $1 - y_i(w^T x_i + b)$ mesure la violation de la contrainte de marge ; lorsqu'il est positif, l'hyperplan est trop proche du point ou mal orienté.

Démonstration des conditions d'optimalité

En annulant les dérivées du Lagrangien par rapport aux variables primales, on obtient les conditions de Karush–Kuhn–Tucker (KKT) :

$$\nabla_w \mathcal{L}(w^*, b^*, \lambda^*) = 0 \quad \Rightarrow \quad w^* = \sum_{i=1}^n \lambda_i^* y_i x_i, \quad (7)$$

$$\frac{\partial \mathcal{L}}{\partial b}(w^*, b^*, \lambda^*) = 0 \quad \Rightarrow \quad \sum_{i=1}^n \lambda_i^* y_i = 0. \quad (8)$$

Ces relations montrent que le vecteur de poids optimal est une combinaison linéaire des exemples d'apprentissage dont les multiplicateurs λ_i sont non nuls. Les contraintes de complémentarité $\lambda_i^* \geq 0$ et $\lambda_i^* (1 - y_i(w^{*T} x_i + b^*)) = 0$ garantissent que les vecteurs pour lesquels $\lambda_i^* > 0$ satisfont $y_i(w^{*T} x_i + b^*) = 1$: ce sont précisément les vecteurs de support.

En substituant w^* dans $\mathcal{L}$ on obtient la formulation duale du problème :

$$\max_{\lambda \in \mathbb{R}^n} \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j x_i^T x_j \quad \text{sous} \quad \lambda_i \geq 0, \sum_{i=1}^n \lambda_i y_i = 0. \quad (9)$$

La méthode d'Uzawa évite de résoudre directement ce problème quadratique en alternant les mises à jour de w, b et λ .

2 Algorithme d'Uzawa

L'algorithme procède par boucles imbriquées. À chaque itération k :

1. **Minimisation interne** (*mise à jour de w et b*). Pour des multiplicateurs λ fixés, on effectue des pas de descente de gradient sur w et b :

$$w \leftarrow w - \eta_w \nabla_w \mathcal{L}, \quad b \leftarrow b - \eta_b \frac{\partial \mathcal{L}}{\partial b},$$

où η_w est un pas d'apprentissage. La descente s'arrête lorsqu'un nombre maximal d'itérations est atteint ou que la norme du gradient devient inférieure à un seuil.

2. **Maximisation externe** (*mise à jour des multiplicateurs*). Les multiplicateurs sont mis à jour par ascension de gradient et projection sur $\mathbb{R}^+_{\geq 0}$:

$$\lambda_i \leftarrow \max(0, \lambda_i + \rho (1 - y_i(w^T x_i + b))),$$

où ρ est un pas de mise à jour. L'algorithme s'arrête lorsque les variations de (w, b, λ) deviennent négligeables.

Cette alternance assure la convergence vers un optimum de la formulation du SVM, à condition de choisir des pas d'apprentissage suffisamment petits. La méthode identifie les *vecteurs de support* : ce sont les observations pour lesquelles $\lambda_i > 0$. Seuls ces points contraignent la position de l'hyperplan.

3 Données utilisées

L'ensemble `data_waam.xlsx` contient $n = 100$ observations. Chaque observation regroupe :

- V_d : vitesse de dépôt (cm/min),
- V_{fil} : vitesse d'alimentation du fil (m/min),
- la variable *Conformité*, égale à +1 pour une pièce conforme et à -1 sinon.

L'échantillon est équilibré (50 conformes et 50 non conformes). La figure 1 montre la répartition des points et les hyperplans obtenus.




FIGURE 1 – Frontière de décision linéaire obtenue par l’algorithme d’Uzawa avec les paramètres w et b indiqués dans le texte. Les cercles verts indiquent les vecteurs de support. Les droites H_0 , H^+ et H^- sont définies par $w^T x + b = 0$ et $w^T x + b = \pm 1$.

4 Implémentation et résultats

Nous avons implémenté l’algorithme d’Uzawa en Python. Les fonctions `df_dw`, `df_db` et `df_dlambda` calculent les gradients. La fonction `inf()` réalise la descente de gradient interne, `sup()` met à jour les multiplicateurs et `uzawa()` orchestre les deux étapes. Les valeurs de pas choisies ($\eta = 10^{-4}$ pour la descente interne et $\rho = 0,01$ pour l’ascension externe) assurent une convergence stable.

En utilisant le script fourni et les paramètres précédents, l’algorithme converge vers les valeurs suivantes pour le vecteur des poids et le biais :

$$w = \begin{pmatrix} 7,12 \\ -5,74 \end{pmatrix}, \quad b = -20,01.$$

Ces paramètres définissent l’hyperplan de décision $f(x) = w^T x + b$. L’évaluation sur l’ensemble d’apprentissage donne un taux de classification de 100 % et met en évidence six vecteurs de support.

Vecteurs de support et analyse

Les six observations dont le multiplicateur de Lagrange est non nul sont listées ci-dessous :

V_d	V_{fil}	Classe
5,5	3,5	-1
5,4	3,4	-1
4,9	2,4	+1
4,5	2,3	-1
5,4	3,4	-1
5,4	3,0	+1

Ces points se situent à proximité immédiate de l'hyperplan séparateur et déterminent la position des droites H_0 , H^+ et H^- . Les autres observations, pour lesquelles le produit $y_i(w^T x_i + b)$ est nettement supérieur à 1, ont des multiplicateurs nuls et n'influencent pas la frontière de décision.

5 Discussion et perspectives

Comparaison des points (H^+ , H^-) et du reste. Les points pour lesquels $w^T x_i + b \approx \pm 1$ définissent les hyperplans H^+ et H^- . Ils correspondent aux essais dont la conformité est la plus incertaine : une légère variation des vitesses peut changer leur étiquette. Les autres points, pour lesquels $|w^T x_i + b| \gg 1$, sont correctement classés avec une marge importante ; ils ne servent qu'à conforter la séparation.

Déploiement du modèle pour le WAAM. Une fois w et b estimés, la prédiction de la conformité pour un nouveau réglage (V_d , V_{fil}) se fait en évaluant le signe de $w^T x + b$. Dans un contexte industriel, on peut intégrer cette fonction de décision dans un système de contrôle afin de choisir automatiquement des vitesses de dépôt et d'alimentation situées du côté "+ 1" de l'hyperplan. Une extension naturelle consiste à enrichir le jeu de données avec d'autres paramètres (matériau, épaisseur de couche, température) et à envisager des SVM non linéaires en utilisant des noyaux.

Conclusion

Le mini-projet 3 a permis de formaliser la séparation linéaire de données WAAM à l'aide d'un SVM et d'implémenter l'algorithme d'Uzawa. Après dérivation du Lagrangien et mise en œuvre des gradients, la méthode converge vers un hyperplan qui sépare parfaitement les essais conformes des essais non conformes. Seuls quelques vecteurs de support influencent la position de l'hyperplan, illustrant le principe de parcimonie des SVM. Ce modèle constitue une base simple pour un système de recommandation de paramètres opératoires dans le procédé WAAM.